Predicción del riesgo de abandono de clientes en una empresa de telecomunicaciones iraní mediante regresión logística bayesiana

Predicting customer churn risk in an Iranian telecommunications company using Bayesian logistic regression

Ianis Ramírez Cárdenas[1,*] y Juan Esteban Acosta Morales[1]

[1] Departamento de Matemáticas, Ciencia de Datos, Universidad Externado de Colombia, Bogotá D. C., Colombia

[*]ianis.ramirez@est.uexternado.edu.co, juan.acosta9@est.uexternado.edu.co

Docente de Estadística Bayesiana: Jairo Alberto Mora Fernandez, jairo.mora1@uexternado.edu.co

Docente de Pensamiento Crítico: Ghislaine Tibaire Murzi Sifontes, ghislaine.murzi@uexternado.edu.co

RESUMEN

Mediante regresión logística bayesiana, se evalúa en qué medida las características de uso, servicio y suscripción observadas durante los primeros nueve meses permiten predecir el abandono de clientes de una empresa de telecomunicaciones iraní al finalizar el mes doce. Se emplearon 2.850 clientes únicos del *Iranian Churn Dataset*, de los cuales 446 registraron abandono (15,6 %), distribuidos en 2.137 observaciones de entrenamiento y 713 de prueba. Las distribuciones previas para las variables de estado del cliente, quejas y antigüedad se establecieron a partir de literatura publicada en otros mercados y se ajustaron mediante el enfoque de *power priors*, mientras que para las demás variables se utilizaron distribuciones débilmente informativas. La estimación se realizó mediante Monte Carlo hamiltoniano (HMC), con cuatro cadenas, valores de $\hat{R} \leq 1{,}003$ y ninguna divergencia. Los resultados muestran que presentar una queja multiplica por 35,3 las *odds* de abandono (intervalo de credibilidad del 95 %: 20,4–62,0), mientras que tener un estado no activo las multiplica por 3,28. Por el contrario, la edad y el tipo de plan no presentan evidencia de un efecto relevante. En términos predictivos, la regresión logística bayesiana y la clásica muestran un desempeño similar: AUC-ROC de 0,929 y 0,930, respectivamente. No obstante, el enfoque bayesiano permite cuantificar la incertidumbre de las predicciones y evidencia diferencias entre la información previa y los resultados observados, particularmente en el efecto de las quejas. Finalmente, Random Forest alcanza un mayor AUC-PR (0,907 frente a 0,765), lo que sugiere la presencia de relaciones no lineales entre las características de los clientes y el abandono.

Palabras Clave: *estadística bayesiana; regresión logística; abandono de clientes (churn); telecomunicaciones; odds; MCMC; Monte Carlo hamiltoniano.*

ABSTRACT

Using Bayesian logistic regression, this study evaluates the extent to which usage, service, and subscription characteristics observed during the first nine months can predict customer churn for an Iranian telecommunications company by the end of the twelfth month. The dataset consists of 2,850 unique customers from the *Iranian Churn Dataset*, 446 of whom churned (15.6 %); the data were split into 2,137 training observations and 713 test observations. Prior distributions for variables related to customer status, complaints, and tenure were established based on literature from other markets and adjusted using a *power priors* approach, while weakly informative priors were used for the remaining variables. Estimation was performed via Hamiltonian Monte Carlo (HMC) with four chains, yielding $\hat{R}$ values $\leq 1{,}003$ and no divergences. The results indicate that filing a complaint increases the odds of churn by a factor of 35.3 (95 % credible interval: 20.4–62.0), while having a non-active status increases the odds by a factor of 3.28. Conversely, age and plan type show no evidence of a significant effect. In terms of predictive performance, Bayesian and classical logistic regression perform similarly, with AUC-ROC values of 0.929 and 0.930, respectively. However, the Bayesian approach allows for the quantification of predictive uncertainty and highlights discrepancies between prior information and observed results—most notably regarding the impact of complaints. Finally, a Random Forest model achieves a higher AUC-PR (0.907 versus 0.765), suggesting the presence of non-linear relationships between customer characteristics and churn.

Keywords: *Bayesian statistics; logistic regression; customer churn; telecommunications; odds ratio; MCMC; Hamiltonian Monte Carlo.*

1. Introducción

Conseguir un nuevo cliente tiende a ser más costoso que retener a uno antiguo. Por ende, anticipar el abandono (churn) es un tema fundamental en el sector de telecomunicaciones, debido a que algunos clientes muestran señales de insatisfacción o desvinculación antes de irse. Si el equipo de retención recibe esa lista con tiempo y logra identificar dichas señales, la posibilidad de reconocer aquellos que tienen mayor riesgo de abandonar el servicio aumentaría.

En este estudio se observan nueve meses de comportamiento para posteriormente dar un resultado en el mes doce, dejando una brecha de planificación de tres meses. Los datos usados fueron publicados por Keramati et al. (2014) y disponibles en el repositorio de la UCI (Iranian Churn,

2020). Tanto el artículo como gran parte de la literatura posterior trabajan el problema mediante la minería de datos.

Asimismo, se usa un enfoque bayesiano por tres razones. Primero, permite expresar las predicciones como probabilidades acompañadas de intervalos que muestran la incertidumbre de los resultados. Segundo, facilita responder preguntas sobre la magnitud de los efectos, por ejemplo: "¿qué tan probable es que presentar una queja multiplique las odds de abandono por más de diez?". Y, finalmente, aprovecha la literatura, es decir, resultados de investigaciones realizadas en otros mercados (Ahn et al., 2006; Customer churn in mobile markets, 2016) que se pueden incorporar como información previa en lugar de empezar de cero. Bajo este lineamiento, se plantea la pregunta de investigación:

¿En qué medida las características de uso, servicio y suscripción de los primeros nueve meses permiten identificar y predecir qué clientes abandonarán al mes doce, y cuáles son las variables que más pesan, para priorizar acciones de retención?

1.1 Objetivos

1.1.1 Objetivo General

Analizar, con un modelo de regresión logística bayesiana, en qué medida las características observadas de uso, servicio y suscripción durante los primeros nueve meses permiten identificar qué clientes tienen mayor riesgo de abandono al mes doce, con el propósito de apoyar la priorización de clientes para acciones de retención.

1.1.2 Objetivos Específicos

- Identificar las características de comportamiento con mayor relación con el abandono, cuantificando su efecto como odds con intervalos de credibilidad.
- Caracterizar el comportamiento de los clientes que abandonan frente a los que permanecen.
- Definir distribuciones previas basadas en la literatura generando cadenas MCMC convergentes ($\hat{R} < 1{,}01$, sin divergencias), para obtener intervalos de credibilidad de los coeficientes y las probabilidades de cada cliente.
- Analizar si la clasificación del riesgo permite ordenar clientes para apoyar la priorización de posibles acciones de retención durante la brecha de planificación de tres meses.

1.2 Estructura del documento

El documento se organiza en siete secciones. La primera corresponde a la introducción; la segunda presenta la revisión de la literatura y el aporte del proyecto. La tercera describe la metodología, incluyendo la población, los datos, su procesamiento, las hipótesis y el modelo utilizado. La cuarta presenta el análisis exploratorio. La quinta explica el pipeline y los experimentos realizados con los distintos modelos. La sexta expone los resultados obtenidos y, finalmente, la séptima presenta las conclusiones.

2. Revisión de la literatura

2.1 Fundamentos teóricos del abandono y de la inferencia bayesiana

El abandono y su costo.. El abandono de clientes ocurre cuando un usuario deja de utilizar los servicios de una empresa. En telecomunicaciones, este fenómeno representa un reto económico, ya que conseguir nuevos clientes suele implicar mayores costos que conservar los actuales. Según un informe de Strategy Analytics para Juvo, los operadores destinan el 90 % de su presupuesto de adquisición de suscriptores a contrarrestar el churn (Capacity Media, sf). Sin embargo, las tasas de abandono varían considerablemente entre mercados. Por ejemplo, Ahn et al. (2006) reportan tasas anuales del 16.9 % en 2003 y del 20.0 % en 2004 para la telefonía móvil en Corea del Sur. Por su parte, Ovum considera aceptables tasas mensuales inferiores al 2 % en planes pospago y al 5 % en prepago (Meyer, 2014). En siete mercados emergentes, las tasas anuales de abandono en prepago se sitúan entre el 37 % y el 80 % (Capacity Media, sf). Estas cifras permiten dimensionar el problema, aunque correspondan a promedios generales y no reflejen necesariamente el riesgo individual de cada cliente.

Regresión logística. La regresión logística es utilizada para estimar la probabilidad de que ocurra un evento con dos posibles resultados, como el abandono o la permanencia de un cliente. El modelo relaciona las características de los usuarios con las odds de abandono mediante una combinación lineal de las variables explicativas. Una de sus principales ventajas es que permite interpretar los coeficientes como razones de momios - que cuantifican la fuerza de asociación entre dos eventos o variables-, lo que facilita identificar qué características están más relacionadas con el abandono y en qué dirección.

Enfoque bayesiano. El enfoque bayesiano permite combinar la información observada en los datos con conocimientos previos sobre el fenómeno a estudiar. Esto se realiza mediante la distribución previa y la verosimilitud, que en conjunto permiten obtener la distribución posterior de los parámetros. La previa permite incorporar evidencia externa por lo que se debe controlar su influencia, para la cual, se puede reducir el peso de la información mediante el enfoque de power priors, ampliando la incertidumbre asociada a las estimaciones iniciales (Ibrahim and Chen, 2000). Pero también, cuando no existe evidencia suficiente, se utilizan distribuciones débilmente informativas que permiten

estimar los parámetros sin imponer supuestos demasiado restrictivos (Gelman et al., 2008).

Estimación. Debido a que la regresión logística no tiene previa conjugada, se recurre a métodos de aproximación numérica, tales como la aproximación de Laplace, la inferencia variacional y los métodos de Monte Carlo mediante cadenas de Markov (MCMC). Al compararlas, se evidencia que la aproximación de Laplace depende de supuestos sobre la forma de la posterior, la inferencia variacional puede subestimar la incertidumbre (Blei et al., 2017), los métodos de Gibbs requieren estructuras específicas para facilitar el muestreo (Polson et al., 2013) y Metropolis-Hastings puede presentar dificultades de eficiencia cuando los parámetros están altamente correlacionados (Gelman et al., 1996). En este estudio se utiliza Monte Carlo hamiltoniano, que aprovecha la información del gradiente de la distribución posterior para generar movimientos más eficientes en el espacio de parámetros (Neal, 2011; Hoffman and Gelman, 2014).

Predicción frente a causalidad. Los coeficientes deben interpretarse manteniendo constantes las demás variables incluidas en el modelo ya que describen asociación y no causalidad. Además, si una variable se registra cerca o después del evento ocurre la fuga de información, que es importante evitar debido a que puede generar una estimación artificialmente alta del desempeño del modelo y reducir su utilidad al aplicarlo en diversas situaciones.

2.2 Antecedentes

Keramati et al. (2014) publicaron el conjunto de datos utilizado en este estudio, compuesto por 3150 clientes seleccionados aleatoriamente de la base de datos del centro de llamadas de un operador iraní durante un periodo de doce meses, de los cuales, 495 son abandonos (15.7 %).Entre sus principales hallazgos, destacan las quejas como una de las variables más relacionadas con el abandono. Sin embargo, el conjunto de datos no incluye registros históricos del operador ni información sobre las tasas de abandono del mercado.

Por su parte, Vatankhah et al. (2016), a partir de encuestas realizadas a 420 clientes de un operador iraní, y Kazami and HejaziNia (2017), mediante un estudio con clientes pospago en Zahedan, identifican factores asociados al abandono, como la calidad del servicio, la insatisfacción, las barreras de cambio y la antigüedad de la tarjeta SIM, pero no reportan estimaciones numéricas que permitan construir las distribuciones previas. Del mismo modo, no se encontró una tasa de abandono publicada que permitiera establecer una referencia específica para el mercado iraní.

Lo que sí existe son efectos publicados en otros mercados. Ahn et al. (2006), en un estudio con 5789 clientes de un operador surcoreano, estiman para los clientes sin uso frente a los activos un $\beta = 1{,}455$ (EE 0.349; OR $\approx 4{,}3$), mientras que para las quejas reportan un $\beta = 0{,}538$ (EE 0.323; OR $\approx 1{,}7$).

Por otro lado, Customer churn in mobile markets (2016) reporta un OR de 0.974 por cada mes adicional de antigüedad del cliente en un operador del Reino Unido. Estos resultados ofrecen referencias cuantitativas para orientar la construcción de las distribuciones previas, aunque es necesario considerar que provienen de mercados diferentes.

Finalmente, desde una perspectiva predictiva, Arai et al. (2023) proponen un método basado en LightGBM para estimar el abandono de clientes. Este sirve como referencia para explorar modelos capaces de identificar relaciones más complejas entre las variables y comparar su desempeño con el de la regresión logística.

2.3 Aporte que se busca realizar

Este estudio realiza cuatro aportes principales. (i) Desarrolla un modelo de regresión logística para los datos de Keramati et al. (2014), con previas sustentadas en evidencia publicada. (ii) incorpora la incertidumbre en los resultados mediante intervalos de credibilidad para los odds ratio y las probabilidades de abandono de cada cliente. (iii) Una comparación con la logística clásica, con reglas simples y con modelos no lineales, además de evaluar qué tanto cambian los resultados al modificar las distribuciones previas. (iv) Analiza las diferencias entre la literatura y los resultados obtenidos, especialmente en el efecto de las quejas, considerando la posibilidad de una fuga de información y las implicaciones de excluir las variables que podrían estar involucradas.

3. Metodología

3.0.1 Población

Como se ha mencionado anteriormente, los datos corresponden al *Iranian Churn Dataset* (UCI Machine Learning Repository, 2020; https://archive.ics.uci.edu/dataset/563/iranian+churn+dataset). Keramati et al. (2014) lo describen como 3150 clientes tomados al azar de la base de datos del centro de llamadas de un operador iraní durante 12 meses. La unidad de análisis es el cliente y no se incorporan variables externas. La base solo incluye clientes con al menos tres meses de antigüedad y activos durante los nueve meses observados, lo que introduce un sesgo de supervivencia que se discute más adelante.

3.0.2 Diccionario de datos

La Tabla 1 describe las variables. Todas provienen directamente de la base de la UCI. Las variables de uso, servicio y suscripción corresponden a los primeros nueve meses; `churn` es el estado al mes 12 (1 = abandona; 0 = permane-

ce). El archivo tiene 14 columnas y ningún valor faltante.

3.0.3 Procesamiento

La base original tiene 3150 filas y no tiene valores faltantes, así que no hubo imputación. El procesamiento tuvo cuatro pasos.

Eliminar duplicados. Se eliminaron 300 filas que eran copias exactas de 165 registros repetidos de 2 a 6 veces. Si se dejan, un mismo cliente podría caer a la vez en entrenamiento y en prueba y el modelo parecería mejor de lo que es. Por ende, quedan 2850 clientes únicos, 446 con abandono (15.6 %), casi la misma tasa que antes (15.7 %).

Retirar variables redundantes. Se excluyeron tres variables. Se eliminó `grupo_edad`, ya que cada grupo corresponde a una sola edad. También, `valor_cliente`, puesto que las demás variables explican el 98 % de su variación (VIF 53.2) y es un cálculo de la empresa con fórmula desconocida. Y, de igual forma se quitó `frecuencia_llamadas`, debido a que tiene $r = 0{,}95$ con `segundos_uso` (VIF 22 y 18), es decir, son muy similares. Continuando, tras el retiro ningún predictor pasa de VIF 2.3, y las variables restantes pasan a ser: fallas de llamada, queja, segundos de uso, frecuencia de SMS, números distintos, meses de suscripción, nivel de cobro, plan, estado y edad.

Partir la base. La partición es por cliente, estratificada y con semilla 42: 2137 clientes de entrenamiento (334 abandonos) y 713 de prueba (112 abandonos).

Estandarizar para el muestreo. Para realizar el MCMC, las variables se centran y se escalan utilizando la desviación estándar calculada con los datos de entrenamiento. Aún así, los resultados se presentan en sus unidades originales para facilitar su interpretación.

3.0.4 Hipótesis

Se plantean las siguientes hipótesis, escritas como afirmaciones sobre la distribución posterior de los coeficientes β_j del modelo:

H1. Tener una queja aumenta las *odds* de abandono, por lo que se espera que $P(\beta_{\text{queja}} > 0 \mid \text{datos})$ sea cercana a 1.

H2. El estado no activo aumenta las *odds* de abandono, como también se ha observado en estudios realizados en Corea.

H3. Un mayor uso de los servicios (segundos, SMS y números distintos), una mayor antigüedad y un nivel de cobro más alto reducen las *odds* de abandono.

H4. Un mayor número de fallas de llamada aumenta las *odds* de abandono, incluso al comparar clientes con niveles de uso similares.

H5. El plan tarifario y la edad tienen un efecto reducido sobre las *odds* de abandono una vez se consideran las demás variables.

H6. El efecto de las quejas es considerablemente mayor que el reportado en estudios anteriores, lo que podría reflejar diferencias entre la información previa y los datos analizados.

3.0.5 Modelo propuesto

Como modelo principal se propone la regresión logística bayesiana. Para el cliente i, con $Y_i = 1$ si abandona al mes 12 y x_{ij} las 10 variables,

$$Y_i \sim \text{Bernoulli}(\pi_i), \quad \text{logit}(\pi_i) = \beta_0 + \sum_{j=1}^{10} \beta_j x_{ij}. \qquad (1)$$

Por el teorema de Bayes, la posterior de los coeficientes es proporcional a la verosimilitud por la previa:

$$P(\beta \mid \mathbf{y}, \mathbf{X}) \propto \prod_{i=1}^{n} \pi_i^{y_i} (1-\pi_i)^{1-y_i} P(\beta). \qquad (2)$$

Cada coeficiente se interpreta mediante una razón de momios (OR), calculada como $\text{OR}_j = e^{\beta_j}$, manteniendo constantes las demás variables. Para facilitar su interpretación, en las variables cuantitativas se consideran incrementos más representativos: 1000 segundos de uso, 10 SMS, 10 números distintos, 6 meses de antigüedad y 10 años de edad. Esto permite evitar OR muy cercanas a 1, que serían difíciles de interpretar si se tomara como referencia el aumento de una sola unidad.

Previas. Las previas principales se construyeron a partir de la evidencia presentada en la sección 2.2. Se trata de previas descontadas, es decir que, sus desviaciones se amplían respecto a los errores estándar publicados, debido a que la evidencia proviene de otro país, época e incluso de definiciones diferentes de las variables.

Cabe recalcar que, ninguna de estas previas se obtiene de la base de datos utilizada ni de Keramati et al. (2014), ya que hacerlo implicaría utilizar la misma información dos veces. La Tabla 2 resume las previas.

El intercepto no se fija a partir de las tasas de abandono del sector (17–20 % anual en Corea y 37–80 % en mercados emergentes de prepago). Esto se debe a que dichas tasas representan promedios generales de abandono, mientras que el intercepto refleja el riesgo estimado para un cliente cuyas variables se encuentran en sus valores promedio, que en esta base corresponde a aproximadamente 3 %. Las tasas del sector se utilizan más adelante como punto de comparación en la evaluación predictiva.

Como referencia, también se ajusta un modelo con una previa débilmente informativa, en el que los coeficientes de las 10 variables siguen una distribución $\beta_j \sim N(0, 2{,}5)$, donde

Variable	Grupo	Tipo	Rango observado	Descripción
fallas_llamada	Servicio	Conteo	0–36	Llamadas fallidas
quejas	Servicio	Binaria	0–1	1 = el cliente presentó alguna queja
meses_suscripcion	Suscripción	Conteo	3–47	Meses totales de suscripción
nivel_cobro	Suscripción	Ordinal	0–10	Nivel de cobro (0 = más bajo)
segundos_uso	Uso	Continua	0–17 090	Segundos totales de llamadas
frecuencia_llamadas	Uso	Conteo	0–255	Número total de llamadas
frecuencia_sms	Uso	Conteo	0–522	Número total de mensajes de texto
numeros_distintos	Uso	Conteo	0–97	Números distintos a los que llamó
plan_tarifa	Suscripción	Binaria	1–2	1 = pago por uso, 2 = contrato
estado	Suscripción	Binaria	1–2	1 = activo, 2 = no activo
edad	Demografía	Ordinal	15–55	Solo toma cinco valores (15, 25, 30, 45, 55)
valor_cliente	Suscripción	Continua	0–2165.28	Valor calculado por la empresa a partir del uso
grupo_edad	Demografía	Ordinal	1–5	Mismo contenido que `edad`
churn	Objetivo	Binaria	0–1	1 = abandona al mes 12

Tabla 1. Variables del *Iranian Churn Dataset*. `grupo_edad` se documenta porque está en la base original, pero se retiró en la preparación.

Parámetro	Evidencia publicada	Previa (escala original)	Qué admite al 95 %
Estado no activo	Cliente "sin uso" frente a activo: $\beta = 1{,}455$ (EE 0.349), OR $\approx$ 4,3; operador coreano, 5789 clientes (Ahn et al., 2006)	$\beta \sim N(1{,}46,\ 1{,}0)$	OR entre 0.61 y 30.6
Queja	Cada queja: $\beta = 0{,}538$ (EE 0.323), OR $\approx 1{,}7$ (Ahn et al., 2006). Aquí es "alguna queja" (0/1); por eso la desviación triplica el EE	$\beta \sim N(0{,}54,\ 1{,}0)$	OR entre 0.24 y 12.2
Meses de suscripción	Cada mes: OR 0.974 (EE $\approx 0{,}003$); operador del Reino Unido (Customer churn in mobile markets, 2016)	$\beta \sim N(-0{,}027,\ 0{,}03)$ por mes	OR por 6 meses entre 0.60 y 1.21
Intercepto y otras 7 variables	Sin evidencia transferible (otras unidades o variables)	$N(0,\ 2{,}5)$ por desviación estándar (Gelman et al., 2008)	Débilmente informativa

Tabla 2. Previas del modelo principal. Las tres previas informadas admiten el "sin efecto" (OR = 1) dentro de su 95 %: orientan la dirección y dejan que los datos contradigan a la literatura.

2.5 corresponde a la desviación estándar. Este es el valor por defecto de rstanarm (Gelman et al., 2008; Goodrich et al., 2024) y permite evaluar cuánto influyen los resultados de la literatura en las estimaciones.

Por otra parte, la regresión logística clásica se estima por máxima verosimilitud sin penalización (equivalente a glm(family = binomial) de R, implementada en Python) y se presentan los resultados con intervalos de Wald.

En la validación cruzada y en la Tabla 14 se usa la versión de scikit-learn, que incluye una penalización L2 por defecto.

Estimación por MCMC. La distribución posterior del modelo no tiene una solución analítica directa, por lo que es necesario recurrir a métodos de aproximación. Se evaluaron diferentes alternativas, entre ellas la aproximación de Laplace y el método de Metropolis de paseo aleatorio. Sin embargo, la primera presentó diferencias en las estimaciones y el segundo no alcanzó los criterios de convergencia establecidos. Por esta razón, se optó por Monte Carlo hamiltoniano (HMC), implementado con `numpy`, utilizando los parámetros que se presentan en la Tabla 3. Por último, los criterios de convergencia se definieron antes de examinar los coeficientes (Vehtari et al., 2021).

Además de revisar la convergencia del modelo, se realizan cuatro validaciones. La primera consiste en la evaluación predictiva posterior, que compara los datos observados con bases simuladas a partir del modelo. La segunda evalúa qué tanto cambian los resultados al modificar las distribuciones previas. La tercera compara las estimaciones con las de la regresión logística clásica y, por último, se analiza la capacidad predictiva del modelo en los 713 clientes del conjunto de prueba. Adicionalmente, se comparan los modelos con menos variables mediante el WAIC, el cual, evalúa si un modelo predice mejor que otro, teniendo en cuenta tanto su ajuste a los datos como su complejidad (Watanabe, 2010).

Parámetro	Valor	Justificación
Cadenas	4	Diagnosticar convergencia ($\hat{R}$)
Calentamiento	1000	Antes de guardar muestras
Muestras por cadena	2000	8000 muestras en total
Semilla	42	Reproducibilidad
$\hat{R}$ máximo	$< 1{,}01$	Criterio de convergencia
n_{eff}/N	$> 0{,}1$	Muestras efectivas
Divergencias	0	Criterio de HMC
Aceptación media	$\approx 0{,}8$	Objetivo del HMC

Tabla 3. Parámetros y criterios del muestreo MCMC.

4. Análisis exploratorio de datos

4.1 Hallazgos principales

4.1.1 Generales

Se identificaron 107 clientes sin registros de uso en segundos, de los cuales 56 abandonaron el servicio (52.3 %), una proporción superior a la tasa general de abandono. Además, después de eliminar los duplicados, se encontraron 14 pares de clientes con las mismas características, pero con resultados de abandono diferentes. Estos se presentan casi siempre entre clientes sin uso registrado y como ningún modelo puede distinguir entre clientes con características idénticas, se decidió conservarlos en la base.

El abandono también se concentra en algunas categorías. Entre los 230 clientes que presentaron quejas, el 82.6 % abandonó el servicio, frente al 9.8 % de quienes no presentaron quejas (2620 clientes). Una diferencia similar se observa según el estado del cliente: donde de los 684 clientes no activos, el 47.5 % abandonó, mientras que entre los 2166 activos la proporción fue del 5.6 %. Por otra parte, el abandono fue del 2.6 % entre los clientes con plan de contrato (229) y del 16.8 % entre quienes tenían pago por uso (2621).

Entre las variables numéricas, el uso es la que muestra la mayor diferencia entre los dos grupos: la mediana de segundos de uso es de 1256.5 entre quienes abandonan y de 3596.5 entre quienes permanecen. Dado que estas variables presentan una distribución muy asimétrica, se compararon las medianas mediante la prueba de Mann–Whitney, que permite comparar dos grupos sin asumir que los datos siguen una distribución normal ($p < 10^{-80}$); y, como con 2850 clientes cualquier diferencia sale significativa, se midió también su tamaño con el delta de Cliff, que va de -1 a 1: aquí vale $-0{,}57$, un efecto grande, refiriéndose a que aproximadamente en 8 de cada 10 pares, el cliente que abandonó registró menos segundos de uso que el que permaneció. En cambio, los meses de suscripción y las fallas de llamada, no muestran diferencias claras ($p = 0{,}078$ y $p = 0{,}43$).

4.1.2 Asociaciones clave

La Fig. 1 y la Fig. 2 muestran las dos señales más fuertes de abandono, con correlaciones punto-biseriales de 0.55 y 0.49, respectivamente. Por su parte, la Fig. 3 muestra que quienes abandonan utilizan menos el servicio, así como la Fig. 4 que permite identificar variables redundantes: los segundos de uso y la frecuencia de llamadas presentan una correlación de $r = 0{,}95$, mientras que la frecuencia de SMS y el valor del cliente tienen una correlación de $r = 0{,}92$. Finalmente, las fallas de llamada, por sí solas, prácticamente no se relacionan con el abandono ($r = 0{,}003$), ya que los clientes que realizan más llamadas también tienden a acumular más fallas.

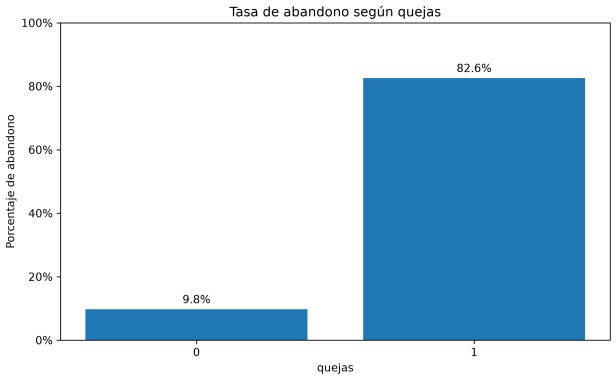


Fig. 1. Tasa de abandono según quejas. Con queja abandona el 82.6 % de los clientes y sin queja el 9.8 %.

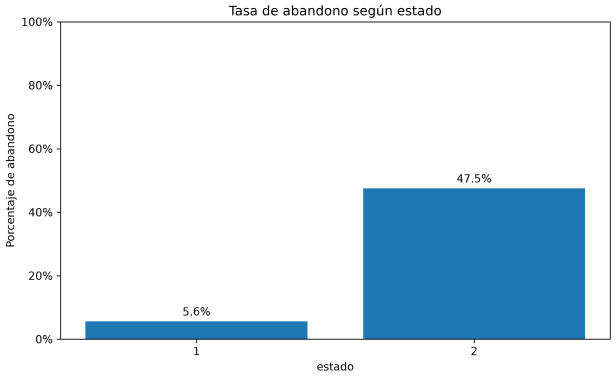


Fig. 2. Tasa de abandono según el estado del cliente (1 = activo, 2 = no activo): 5.6 % y 47.5 %.

5. Modelos

5.1 Pipeline

Antes de ajustar los modelos, se establece un pipeline. Este proceso divide los datos en dos conjuntos: entrenamiento y prueba, y evita que la información del conjunto de prueba influya en las decisiones del modelamiento. Para ello, la limpieza de los datos, la selección de variables y la partición se definen antes del ajuste. Los modelos se entrenan únicamente con los datos de entrenamiento, mientras que el conjunto de prueba se utiliza una sola vez, al final, para evaluar su desempeño. La Fig. 5 resume este proceso.

5.2 Experimentos

Se realizó un experimento con cada uno de los modelos propuestos.

- **Logística bayesiana principal** (previas de la literatura) y **débil** (previas por defecto).
- **Logística clásica** por máxima verosimilitud, con los mismos datos y la misma partición.

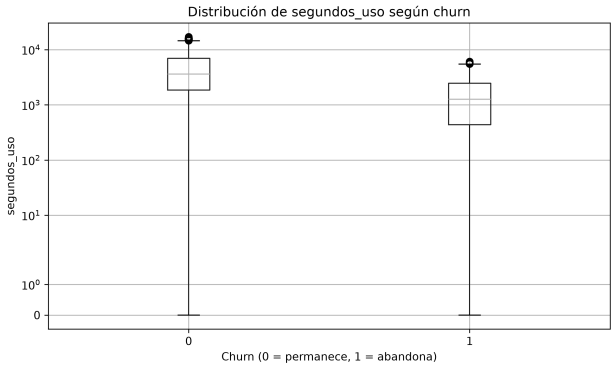


Fig. 3. Distribución de los segundos de uso según la condición final. Quienes abandonan usan menos el servicio.

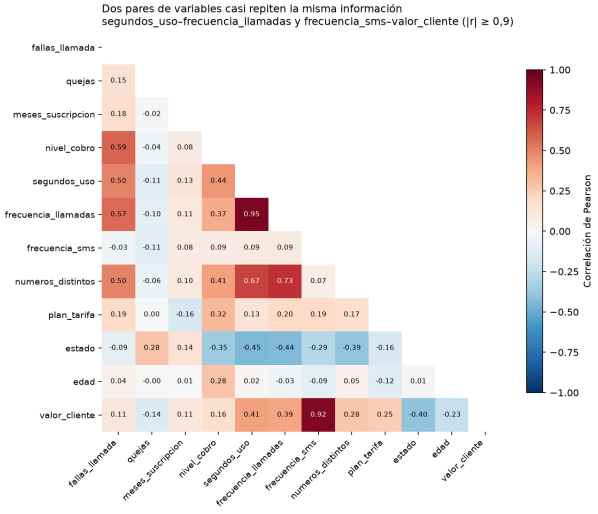


Fig. 4. Correlaciones entre las variables. Las de uso y valor del cliente están muy relacionadas entre sí.

- **Variantes con menos variables**: sin estado, sin quejas, sin ambos y solo uso y fallas. Esto sirve para medir cuánto depende el modelo de las variables sospechosas de fuga.
- **Modelos no lineales**: Árbol de decisión (profundidad 4), bosque aleatorio (random forest) y boosting. Se evaluaron 12 configuraciones (4 técnicas $\times$ 3 conjuntos de variables), mediante validación cruzada de cinco pliegues en el conjunto de entrenamiento y una única evaluación final en el conjunto de prueba.
- **Reglas simples de referencia**: R1 (contactar a quien se quejó) y R2 (quejas o estado no activo).

El desempeño se evaluó mediante cuatro criterios definidos antes de examinar los resultados del conjunto de prueba: (i)Alcanzar una AUC-PR de al menos 0.50; (ii) Identificar al menos tres puntos porcentuales más de abandonos que R2, manteniendo la misma cantidad de contactos; (iii) Alcanzar una AUC-PR de al menos 0.31 sin incluir las variables quejas ni estado; y (iv) Mantener resultados estables

Pipeline

limpieza ..... Quita 300 duplicados y `grupo_edad`
selección ..... 10 variables, sin `valor_cliente` ni `frecuencia_llamadas`
partición ..... 2137 entrenamiento / 713 prueba (semilla 42)
ajuste ..... Previas + HMC solo con entrenamiento
validación ..... $\hat{R}$, n_{eff}, WAIC, chequeo predictivo
prueba ..... Se evalúa una sola vez

Fig. 5. Estructura del pipeline de preprocesamiento y modelamiento.

Métrica	HMC (usado)	Metropolis
$\hat{R}$ máximo	1.003	1.028
n_{eff}/N mínimo	0.549	0.020
Divergencias	0	—
Tiempo (s)	29.3	2.8
Cumple $\hat{R} < 1{,}01$	Sí	No

Tabla 4. Diagnósticos de convergencia (4 cadenas, 8000 muestras).

entre la validación cruzada y la prueba.

En este caso, la métrica principal es la AUC-PR, ya que, con una proporción de abandonos del 15.7 %, su valor de referencia al azar es 0.157.

6. Presentación de resultados

6.1 Convergencia MCMC

El muestreo presentó buenos resultados de convergencia: el valor máximo de $\hat{R}$ fue 1.003, el tamaño efectivo mínimo de muestra (n_{eff}) fue de 4392 (n_{eff}/N entre 0.55 y 0.70), no se registraron divergencias y la tasa promedio de aceptación fue de 0.83. Además, las cuatro cadenas recorrieron regiones similares y sus distribuciones se superponen (Fig. 6). Incluso la Tabla 4 compara el desempeño de HMC con el método de Metropolis de paseo aleatorio. Este último no alcanzó el criterio de convergencia con el mismo número de muestras, mientras que HMC obtuvo aproximadamente 28 veces más muestras efectivas por iteración.

6.2 Métricas de validación cruzada y de prueba

La Tabla 5 presenta las métricas obtenidas mediante validación cruzada con las 10 variables. Los resultados de las regresiones logísticas clásica y bayesiana son similares, mientras que el bosque aleatorio (random forest) y el boosting muestran un mejor desempeño.

En la muestra de prueba (Tabla 6), los modelos bayesiano y clásico presentan resultados prácticamente iguales: la probabilidad asignada a un mismo cliente difiere como máximo en 5.5 puntos entre ambos modelos. La ventaja en el marco bayesiano no está en predecir mejor, sino en cuantificar la incertidumbre de cada predicción y permitir incorporar información previa. Por aparte, random forest logra ordenar mejor a los clientes, con una AUC-PR superior en

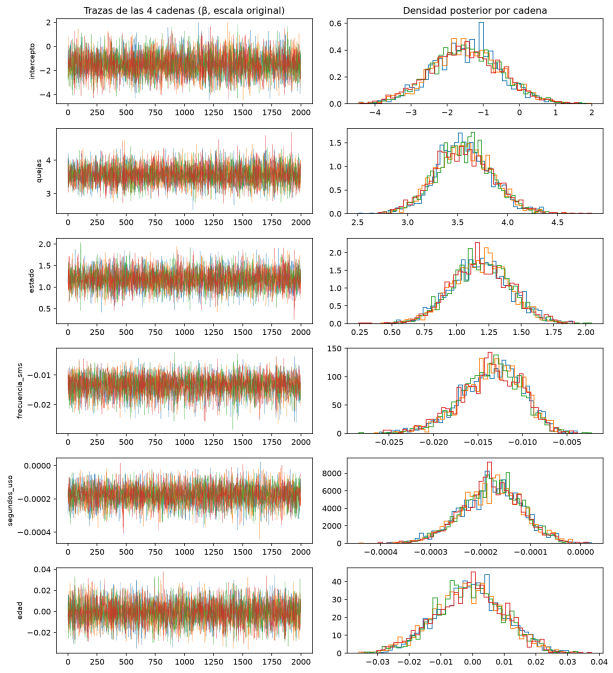


Fig. 6. Trazas y densidades por cadena de seis parámetros (escala original). Las cuatro cadenas se superponen.

Modelo (10 var.)	AUC-ROC	AUC-PR	Exhaustividad
Logística (regularizada)	0.929 ± 0.018	0.741 ± 0.046	0.455 ± 0.041
Árbol (profundidad 4)	0.904 ± 0.027	0.691 ± 0.039	0.533 ± 0.062
Bosque aleatorio	$\mathbf{0.977} \pm 0.008$	$\mathbf{0.894} \pm 0.048$	$\mathbf{0.748} \pm 0.031$
Boosting	0.974 ± 0.008	0.890 ± 0.030	0.737 ± 0.040

Tabla 5. Validación cruzada de cinco pliegues (media $\pm$ desviación entre pliegues). En negrita, el mejor valor.

0.14, y permite identificar el 91.1 % de los abandonos al contactar al 20 % de los clientes, frente al 73.2 % que alcanza el modelo bayesiano. Finalmente, los resultados de la validación cruzada y de la prueba son similares, lo que sugiere que los modelos no sobreajustaron.

La regla R1, que consiste en contactar a los clientes que presentaron quejas (64 clientes), identifica el 48.2 % de los abandonos, el mismo porcentaje que el modelo bayesiano al contactar a la misma cantidad de clientes. Y, la regla R2, que incluye a quienes presentaron quejas o tienen estado no activo (190 clientes, equivalentes al 26.6 % de la base), captura el 86.6 % de los abandonos. Así como el modelo bayesiano que alcanza el 85.7 % con la misma cantidad de contactos, es decir, identifica un abandono menos de los 112 registrados. La ventaja de este último es que permite ordenar a todos los clientes según su riesgo de abandono y ajustar la cantidad de contactos a la capacidad disponible. Por ejemplo, al contactar al 20 % de los clientes, identifica el 73 % de los abandonos, algo que R2 no permite. En otras palabras, R2 funciona un poco mejor cuando se contactan 190 clientes, pero el modelo bayesiano permite adaptar la selección a diferentes capacidades de contacto,

Métrica (713 clientes de prueba)	Bayesiana	Clásica	Bosque
AUC-ROC	0.929	0.930	**0.975**
AUC-PR (azar = 0.157)	0.765	0.766	**0.907**
Exhaustividad / precisión (umbral 0.5)	0.48 / 0.83	0.48 / 0.83	**0.77 / 0.91**
Falsos positivos / falsos negativos	11 / 58	11 / 58	**8 / 26**
Abandonos capturados al contactar 10 %	48.2 %	48.2 %	**58.9 %**
. . . al 20 %	73.2 %	72.3 %	**91.1 %**
. . . al 30 %	90.2 %	90.2 %	**96.4 %**

Tabla 6. Predicción en la muestra de prueba. En negrita, el mejor valor.

Parámetro	Media	DE	2.5 %	97.5 %
Intercepto	−1,467	0.949	−3,340	0.417
Fallas de llamada	0.0828	0.0167	0.0509	0.1154
Queja	3.564	0.280	3.017	4.127
Segundos de uso	$-1{,}78\times10^{-4}$	$0{,}60\times10^{-4}$	$-3{,}00\times10^{-4}$	$-0{,}62\times10^{-4}$
Frecuencia de SMS	−0,0135	0.0034	−0,0209	−0,0075
Números distintos	−0,0407	0.0108	−0,0634	−0,0204
Meses de suscripción	−0,0298	0.0100	−0,0492	−0,0106
Nivel de cobro	−0,325	0.136	−0,604	−0,072
Plan (contrato)	−0,192	0.757	−1,780	1.240
Estado (no activo)	1.188	0.227	0.751	1.631
Edad	−0,0008	0.0108	−0,0226	0.0200

Tabla 7. Resumen posterior de β en la escala original (previa de la literatura).

gracias a que ordena a todos los clientes según su riesgo de abandono.

6.3 Interpretación del modelo

6.3.1 Razones de momios

La Tabla 7 presenta las distribuciones posteriores de los coeficientes, mientras que la Tabla 8 muestra su interpretación en términos de razones de momios y las compara con las estimaciones de la regresión logística clásica (Fig. 7 y Fig. 8).

Queja. Es la señal más fuerte. Las *odds* de abandono de un cliente que se quejó son unas **35 veces** las de uno que no (IC 95 %: 20 a 62), y la probabilidad de que el efecto supere 10 veces es prácticamente 1. Esto confirma la hipótesis 1.

Estado. Estar no activo multiplica las *odds* por 3.3 (2.1 a 5.1), un valor cercano al 4.3 publicado en Corea (hipótesis 2).

Uso y suscripción. Quien usa más el servicio tiene menos riesgo de irse. Por cada 1000 segundos adicionales de uso, las *odds* bajan un 16 %; por cada 10 SMS más, un 13 %; y por cada 10 números distintos a los que llama, un 33 %. La antigüedad también tiene importancia: seis meses más reducen las *odds* un 16 %, un efecto similar al publicado para el Reino Unido (OR de 0.974 por mes, cerca de 0.85 por seis meses). Cada nivel más de cobro las baja un 28 % confirmando la hipótesis 3.

Fallas de llamada. Cada falla adicional aumenta las *odds* de abandono en un 8.6 % (hipótesis 4). Este efecto no se ve

Variable (unidad)	OR bayesiana (IC de credibilidad 95 %)	$P(\beta > 0)$	OR clásica (IC de confianza 95 %)	Ancho bayes / clásica
Queja (sí frente a no)	**35.31** (20.43, 61.98)	1.000	43.91 (23.81, 80.98)	0.91
Estado (no activo frente a activo)	**3.28** (2.12, 5.11)	1.000	3.18 (2.03, 4.97)	0.98
Fallas de llamada (+1)	1.086 (1.052, 1.122)	1.000	1.085 (1.050, 1.121)	0.99
Segundos de uso (+1000)	0.837 (0.741, 0.940)	0.001	0.837 (0.743, 0.943)	1.00
Frecuencia de SMS (+10)	0.874 (0.812, 0.928)	0.000	0.872 (0.811, 0.938)	0.92
Números distintos (+10)	0.666 (0.530, 0.815)	0.000	0.665 (0.536, 0.825)	0.99
Meses de suscripción (+6)	0.836 (0.744, 0.939)	0.003	0.837 (0.737, 0.951)	0.91
Nivel de cobro (+1)	0.723 (0.547, 0.931)	0.004	0.722 (0.551, 0.947)	0.98
Plan (contrato frente a pago por uso)	0.83 (0.17, 3.46)	0.412	0.96 (0.22, 4.19)	1.03
Edad (+10 años)	0.992 (0.798, 1.221)	0.472	0.998 (0.811, 1.227)	1.03

Tabla 8. Razones de momios (OR) de la logística bayesiana (previa de la literatura) frente a la clásica. Todas las lecturas son manteniendo constantes las demás variables.

a simple vista: por sí sola, la variable casi no se relaciona con el abandono ($r = 0{,}003$). Una razón sería que quienes más usan el servicio también acumulan más fallas, pero a la vez son los que menos abandonan, y ambos efectos se cancelan. Por lo que, al comparar clientes con el mismo nivel de uso, el modelo separa esas dos cosas y deja ver que, a igual uso, tener más llamadas fallidas sí aumenta el riesgo de irse.

Plan y edad. Sus intervalos incluyen el 1, así que no hay evidencia de que afecten el abandono (hipótesis 5). La probabilidad de que el plan de contrato reduzca las *odds* es de 0.59, apenas mayor que lanzar una moneda, y la edad tiene un 62 % de probabilidad de estar entre 0.9 y 1.1, es decir, de no tener efecto práctico. Además, en el plan de contrato solo hay 4 abandonos en entrenamiento, por lo que hay muy poca información para estimar su efecto.

Las dos regresiones logísticas llegan a conclusiones similares: para las 10 variables, ambos modelos coinciden en si los intervalos incluyen o no el valor que representa ausencia de efecto. Nueve coeficientes se encuentran a 0.22 errores estándar o menos de sus respectivas estimaciones clásicas. La excepción es la variable quejas, cuya estimación se diferencia en 0.70 errores estándar (OR de 35 frente a 44), debido a que la previa la acerca al efecto reportado en la literatura. Aun así, los intervalos tienen una amplitud muy parecida, con razones entre 0.90 y 1.03.

Es necesario tener en cuenta que la principal diferencia está en la interpretación de los intervalos: uno de credibilidad del 95 % indica que, dados el modelo, los datos y la previa, hay un 95 % de probabilidad de que el OR esté dentro de ese rango. En cambio, un intervalo de confianza del 95 % significa que, si se repitiera el estudio muchas veces, el 95 % de los intervalos construidos con ese método contendría el verdadero valor. Además, el modelo bayesiano permite calcular directamente $P(\mathrm{OR}_{\mathrm{queja}} > 10 \mid \text{datos}) = 1{,}00$, una probabilidad que el valor p no proporciona.

Como complemento, random forest permite identificar qué variables tienen mayor peso en un modelo no lineal (Fig. 9). Al desordenar cada variable, la AUC-PR disminuye 0.33 para las quejas, 0.21 para el estado, 0.09 para los segundos de uso y 0.07 para los meses de suscripción. En cambio, el plan y el nivel de cobro tienen muy poca influencia. El orden anterior coincide con el de las principales variables identificadas por la regresión logística bayesiana.

Cliente típico	Prob. posterior	IC 95 %
Activo, sin queja	6.2 %	(4.3 %, 8.5 %)
Activo, **con queja**	**69.3 %**	(55.9 %, 80.7 %)
No activo, sin queja	17.7 %	(13.5 %, 22.5 %)
No activo, con queja	88.0 %	(81.4 %, 93.1 %)

Tabla 9. Probabilidad posterior de abandono del cliente típico.

6.3.2 Incertidumbre por cliente

Para ejemplificar esta sección, se utiliza un cliente típico construido a partir de las medianas de cada variable (6 fallas, 3030 segundos de uso, 22 SMS, 21 números distintos, 35 meses de suscripción, nivel de cobro 0, plan de pago por uso y 30 años), como se muestra en la Tabla 9. Para este cliente, presentar una queja aumenta la probabilidad de abandono en 63 puntos (entre 51 y 74).

El intervalo del 95 % de probabilidad de abandono tiene una amplitud mediana de 4.4 puntos porcentuales, pero en el 10 % de los clientes supera los 16 puntos. Un caso permite verlo mejor (Fig. 10): un cliente con queja y plan de contrato tiene una probabilidad media de abandono del 31 %, pero su intervalo va del 7 % al 64 %. Esto ocurre porque hay muy pocos clientes con contrato en los datos y, por tanto, menos información para estimar su riesgo.

La regresión logística clásica solo proporcionaría una estimación puntual, sin expresar esta incertidumbre de la misma manera. Para el equipo de retención, un intervalo tan amplio en un cliente que presentó una queja puede ser una señal para revisar su caso con mayor detalle antes de decidir qué acción tomar.

6.4 Evaluación predictiva y sensibilidad a la previa

A partir de las muestras posteriores, se simularon 4000 bases de entrenamiento. La tasa de abandono simulada fue

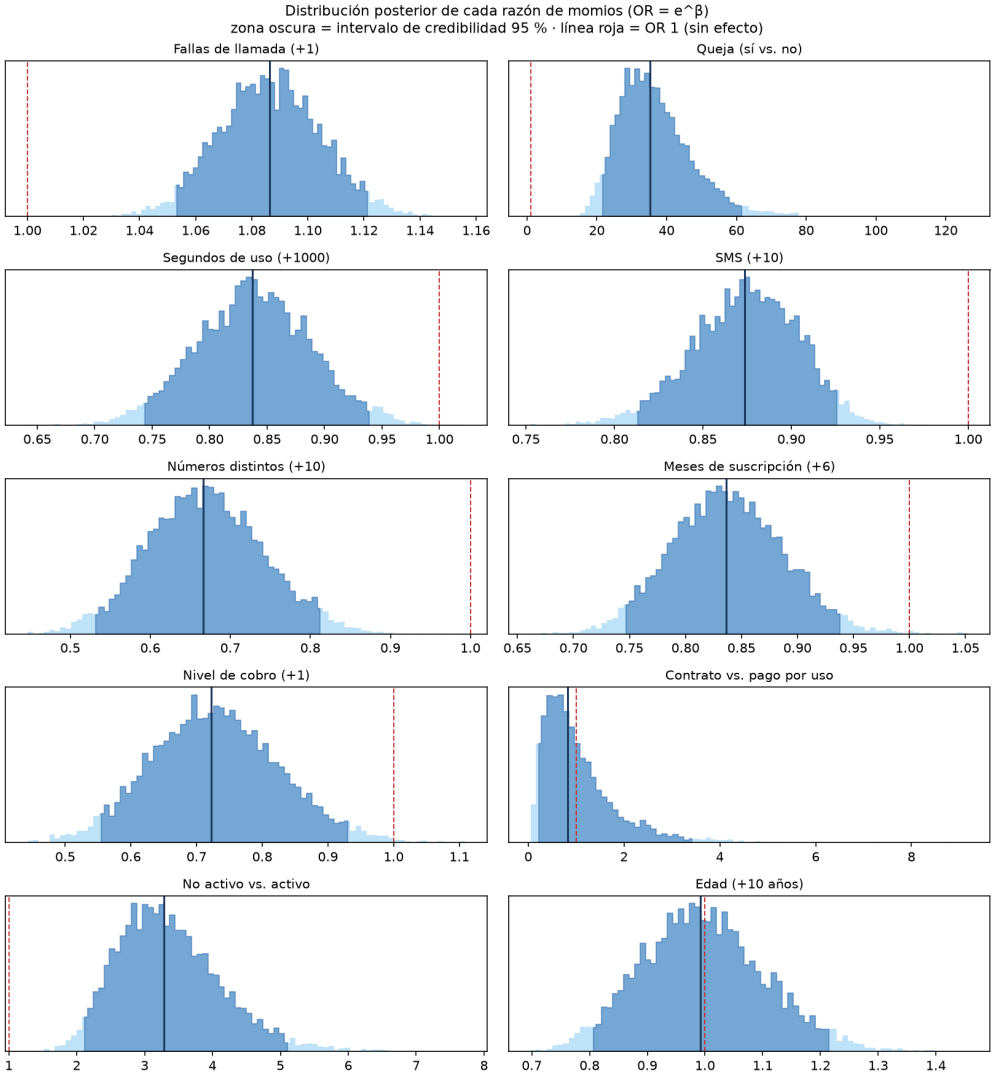


Fig. 7. Distribución posterior de cada razón de momios. La zona oscura es el intervalo de credibilidad del 95 % y la línea roja marca OR = 1 (sin efecto).

del 15.7 % en promedio, con un intervalo del 14.1 % al 17.3 %, que incluye la tasa observada del 15.6 % (p predictivo = 0.52). Lo mismo ocurre al revisar los distintos grupos de clientes (Tabla 10, Fig. 11). Además, todos los valores p predictivos se encuentran entre 0.32 y 0.59, lo que indica que el modelo logra reproducir los datos sin mostrar señales claras de mal ajuste.

De igual modo, la tasa simulada del 15.7 % es ligeramente inferior a las tasas reportadas en Corea (17–20 %) y mucho menor que las del mercado de prepago en países emergentes (37–80 %). Esta diferencia puede estar relacionada con un sesgo de supervivencia, ya que la base solo incluye clientes con al menos tres meses de antigüedad que permanecieron activos durante los nueve meses observados.

Para evaluar cuánto influye la literatura en los resultados,

Grupo	Obs.	Sim. (media)	Sim. 95 %	p
Total	15.6	15.7	14.1–17.3	0.52
Sin queja	10.0	10.2	8.6–11.9	0.59
Con queja	81.9	80.1	73.5–86.1	0.32
Activo	5.7	5.7	4.4–7.1	0.51
No activo	46.9	47.0	42.1–52.1	0.53
Pago por uso	16.7	16.8	15.1–18.4	0.51
Contrato	2.4	2.5	0.6–6.1	0.53

Tabla 10. Chequeo predictivo posterior: tasa de abandono (%) observada y simulada en entrenamiento.

se modificaron las desviaciones de las tres previas basadas en la literatura, multiplicándolas por 0.5, 2 y 4. Para posteriormente, comparar los resultados con los de la previa débil (Tabla 11, Fig. 12). Tras analizar, se evidencia que los resultados son estables para todas las variables, excepto para las quejas. El OR del estado se mantiene entre 3.21

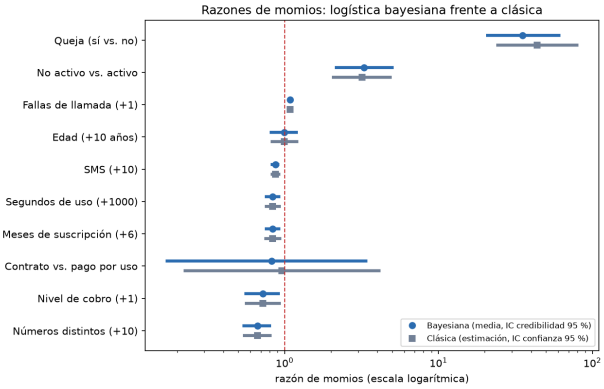


Fig. 8. OR bayesiana frente a clásica con sus intervalos.

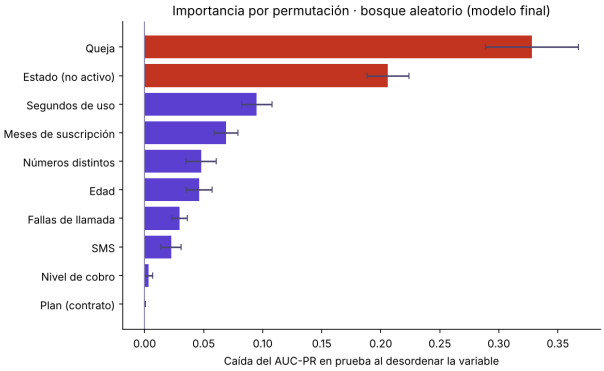


Fig. 9. Importancia por permutación en el bosque aleatorio: caída del AUC-PR en prueba al desordenar cada variable.

y 3.46, mientras que los demás cambian 0.03 o menos.

Cabe recalcar que el efecto de las quejas varía según el peso que se le dé a la literatura (OR entre 21 y 47). Sin embargo, incluso con la previa más restrictiva, el límite inferior del intervalo (13.6) sigue estando muy por encima de 1. Por otra parte, la AUC-ROC en el conjunto de prueba se mantiene en 0.929 en todos los escenarios.

La previa de las quejas situaba el OR alrededor de 1.7, mientras que los datos lo ubican cerca de 47. La estimación posterior queda entre ambos valores, pero más cerca de los datos, con un OR de 35 (Fig. 13). Esto respalda H6 y permite identificar una diferencia que sería difícil de observar sin expresar la previa de manera explícita.

Una posible explicación está en la forma de medir la variable. En el estudio de Corea se analizó el efecto de *cada* queja adicional, utilizando datos de los meses anteriores al abandono. En cambio, en esta base solo se registra si el cliente presentó alguna queja, sin indicar cuándo ocurrió. Si la queja se registró cerca del momento del abandono, su efecto podría estar sobreestimado, lo cual, sería una posible fuga de información.

En el caso del estado y la antigüedad, la literatura y los datos muestran resultados más consistentes: las estimaciones

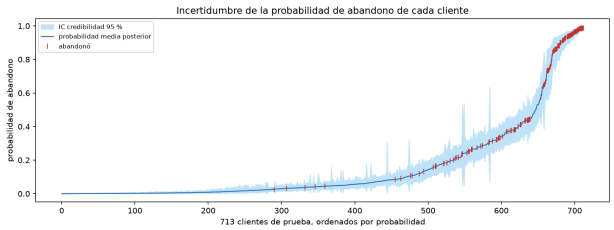


Fig. 10. Incertidumbre de la probabilidad de abandono por cliente de prueba.

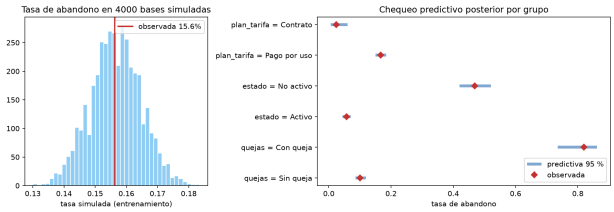


Fig. 11. Chequeo predictivo posterior por grupo.

posteriores se mantienen dentro de los rangos establecidos por las previas y cambian muy poco entre las distintas versiones del modelo.

6.5 Modelos con menos variables

La Tabla 12 compara el modelo completo con otras versiones que excluyen las dos variables que podrían presentar fuga de información. Concluyendo así que, la queja es imprescindible, ya que al quitarla, el ajuste del modelo empeora en 121 puntos de elpd (unos siete errores estándar) y la AUC-PR cae de 0.76 a 0.53. El elpd mide qué tan bien predice el modelo datos nuevos, y mientras más alto es, mejor. En cambio, el estado aporta poco una vez se conoce la queja, lo que reduce la preocupación de que fuera casi el resultado mismo. Aun sin estado ni queja, el modelo conserva capacidad de anticipar el abandono: su AUC-PR de 0.46 es casi tres veces la tasa base (0.157), aunque solo captura la mitad de los abandonos al contactar al 20 % de los clientes.

6.6 Priorización para el equipo de retención

La diferencia entre la regresión logística y random forest está en la forma en que cada modelo analiza la información. La regresión logística supone que las variables tienen una relación lineal con el riesgo de abandono y que sus efectos son independientes entre sí. Sin embargo, en la realidad, el comportamiento de los clientes no siempre sigue ese patrón. Por ejemplo, un cliente que no registra ningún uso del servicio puede tener un comportamiento muy distinto al de uno que lo utiliza poco, y esa diferencia no necesariamente se representa bien con una relación lineal. El bosque aleatorio, por su parte, puede identificar este tipo de relaciones y combinar distintas características de los clientes. Por eso, los dos modelos se complemen-

Previa	OR queja (IC 95 %)	OR estado	OR +10 núm.
Literatura, desv. ×0,5	20.7 (13.6, 32.4)	3.46	0.681
Literatura (principal)	**35.3 (20.4, 62.0)**	3.28	0.666
Literatura, desv. ×2	43.4 (24.7, 78.8)	3.23	0.663
Literatura, desv. ×4	46.3 (26.2, 84.9)	3.22	0.662
Débilmente informativa	46.9 (26.3, 86.9)	3.21	0.660

Tabla 11. Sensibilidad a la previa.

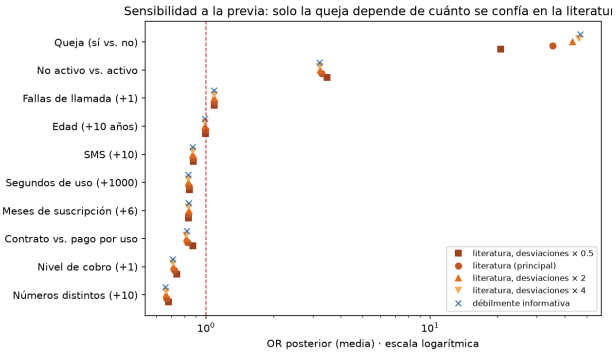


Fig. 12. Sensibilidad de los OR a la previa.

tan: la regresión logística bayesiana ayuda a entender qué factores están relacionados con el abandono, mientras que el bosque aleatorio permite ordenar a los clientes según su riesgo y facilitar la priorización de los contactos por parte del equipo de retención.

Al utilizar las predicciones del bosque para los 713 clientes del conjunto de prueba, se observa que el primer decil de mayor riesgo concentra 67 de los 112 abandonos, mientras que los dos primeros deciles reúnen 102. Esto significa que el modelo logra identificar el 91.1 % de los abandonos al seleccionar el 20 % de los clientes con mayor riesgo. La Tabla 13 muestra cómo cambian los resultados según la cantidad de clientes que la empresa puede contactar.

En general, cuanto mayor sea el número de contactos, más abandonos se pueden identificar. Sin embargo, también aumenta la posibilidad de contactar a clientes que finalmente no abandonan el servicio. Por eso, la decisión depende de la capacidad del equipo y de la importancia que la empresa le dé a cada tipo de error.

Para tomar dicha decisión, también se compararon distintos costos asociados a las equivocaciones del modelo. Un falso negativo ocurre cuando el modelo no identifica a un cliente que finalmente abandona; un falso positivo, cuando señala como riesgoso a alguien que permanece en el servicio. Si el no detectar a un cliente que abandona cuesta cinco o diez veces más que contactar innecesariamente a uno que permanece, el umbral que minimiza el costo es 0.20. Con este valor se obtienen 54 falsos positivos y 6 falsos negativos. En cambio, si el costo de un falso negativo es solo dos veces mayor, el umbral óptimo pasa a 0.35, con 26 falsos positivos y 14 falsos negativos. Para lo anterior, es necesario tener en cuenta que estos valores no representan costos monetarios reales.

Modelo bayesiano	Δelpd $\pm$ EE	AUC-ROC	AUC-PR	Capt. 20 %
Completo (10 var.)	0	0.929	0.765	73.2 %
Sin estado	$-11{,}9 \pm 4{,}6$	0.916	0.739	71.4 %
Sin quejas	$-120{,}7 \pm 16{,}9$	0.876	0.528	61.6 %
Sin estado ni quejas	$-149{,}4 \pm 17{,}7$	0.841	0.461	51.8 %
Solo uso y fallas	$-170{,}4 \pm 18{,}2$	0.826	0.456	51.8 %

Tabla 12. Modelos con menos variables (elpd por WAIC; más alto es mejor).

Capacidad	Contactados	Abandonos ident.	Precisión
10 %	71	66 (58.9 %)	93.0 %
20 %	143	102 (91.1 %)	71.3 %
30 %	214	108 (96.4 %)	50.5 %

Tabla 13. Priorización con el bosque aleatorio (713 clientes de prueba, 112 abandonos).

7. Conclusión y discusión de resultados

En general, se cumplieron los objetivos del proyecto. Se identificaron las variables más relacionadas con el abandono y se estimó la magnitud de sus efectos mediante intervalos de credibilidad. También se describieron las características de los clientes que abandonaron el servicio, se construyeron distribuciones previas basadas en la literatura y se comprobó que las cadenas alcanzaran una buena convergencia. Además, se evaluó la capacidad de predicción de los modelos y se compararon sus resultados con los de la regresión logística clásica, las reglas simples y los modelos no lineales.

La Tabla 14 resume el cumplimiento de los criterios de éxito. El bosque aleatorio fue el único modelo que cumplió los cuatro criterios. Por su parte, las dos regresiones logísticas cumplieron el primer y tercer criterio, más no el segundo puesto que, al contactar al mismo número de clientes que la regla R2, identificaron prácticamente la misma cantidad de abandonos. Por tanto, aunque las regresiones logísticas permiten interpretar los factores asociados al abandono, el bosque aleatorio obtuvo mejores resultados para priorizar a los clientes que deben ser contactados.

7.1 Conclusiones y trabajo futuro

1. La queja es la señal dominante (H1). Quien se quejó tiene unas 35 veces las *odds* de abandonar de quien no (IC 95 %: 20 a 62); para un cliente típico activo, la probabilidad pasa de 6 % a 69 %. Le siguen el estado no activo (OR 3.3; H2) y, con efectos más evidentes, el menor uso y la menor antigüedad (H3) y cada falla de llamada (+8.6 %; H4).

2. Edad y plan no aportan en presencia de las demás variables: sus intervalos contienen el 1 (H5).

3. La evidencia externa confirma el estado y la antigüe-

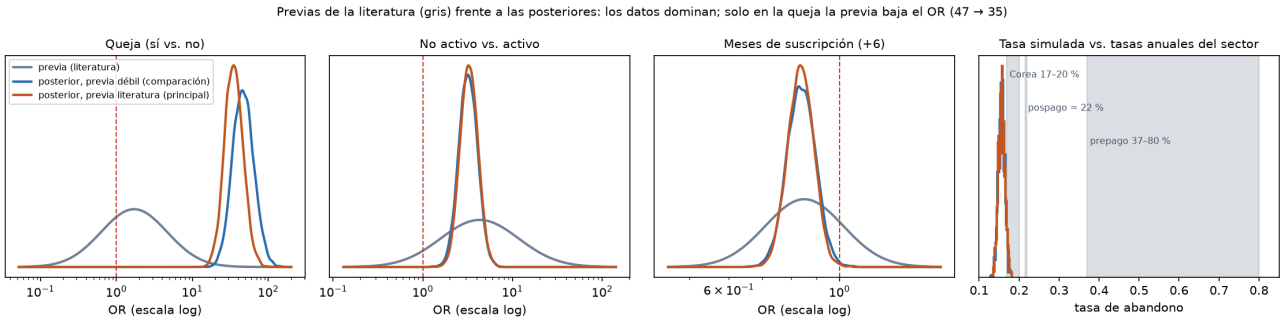


Fig. 13. Previas de la literatura (gris) frente a las posteriores para la queja, el estado y la antigüedad, y tasa simulada frente a las tasas anuales del sector.

Modelo	C1: AUC-PR $\geq 0{,}50$	C2: $\geq +3$ pts vs. R2	C3: AUC-PR s/queja ni estado $\geq 0{,}31$
Logística bayesiana	0.765 (sí)	−0,9 (no)	0.461 (sí)
Logística (regularizada)	0.767 (sí)	−0,9 (no)	0.461 (sí)
Bosque aleatorio	0.907 (sí)	+8,9 (sí)	0.804 (sí)

Tabla 14. Criterios de éxito fijados antes de ver la prueba. La logística de esta tabla es la de scikit-learn (con penalización L2 por defecto), la misma de la Tabla 5; la "clásica" de la Tabla 6 es la de máxima verosimilitud sin penalización (AUC-PR 0.766).

dad, pero no el tamaño de la queja (H6). El efecto observado es mucho mayor que el publicado, lo que puede indicar que la queja se registró cerca del abandono.

4. Las dos logísticas llegan a las mismas conclusiones y predicen igual (AUC-ROC 0.929 y 0.930). La previa solo se nota donde la literatura y los datos chocan (la queja) o donde hay pocos datos (el plan). Lo que agrega el enfoque bayesiano es la inclusión y lectura de la incertidumbre, un rango para la probabilidad de cada cliente y la incorporación de lo que ya se sabía previamente a los datos.

5. Respuesta a la pregunta. La información de los nueve meses anticipa bien el abandono: AUC-PR 0.765 en la logística frente a 0.16 del azar. Buena parte de esa capacidad está en la queja y el estado: sin ellas baja a 0.46. Un bosque aleatorio con las mismas variables llega a 0.91, y a 0.80 sin queja ni estado, de modo que la señal del uso y la suscripción existe, pero no es lineal.

Limitaciones. Las afirmaciones son predictivas, no de explicación causal. Por eso, que la queja se asocie con el abandono no significa que evitar quejas lo reduzca. No se sabe cuándo se registraron la queja y el estado, si fue cerca del mes doce serían casi el resultado, y el modelo sin ellas es honesto. Las previas vienen de otros mercados (Corea, Reino Unido) y, para la queja, de una variable definida distinto, por eso se descontaron y se reporta la sensibilidad. Los coeficientes de uso, que están correlacionados, se leen a igualdad de las demás. La logística es lineal en los log-momios y sin interacciones. Los datos corresponden a un solo operador, un año y solo voz y SMS, y tienen sesgo de supervivencia, por lo que no se generalizan a otros mercados. Además, usar estos modelos con clientes reales exige cuidar la privacidad de los datos y asumir el costo de los falsos positivos (recursos mal usados) y de los falsos negativos (oportunidad perdida).

Trabajo futuro. Una aplicación modificada sería un modelo bayesiano que admita no linealidades, con interacciones o *splines*, para unir la interpretabilidad de la logística con el poder predictivo del bosque. También conviene verificar que las variables usadas estén disponibles en el momento en que se quiere anticipar el abandono antes de usar el modelo en una estrategia real de retención, y probar otras previas o datos de otros operadores.

Nota importante. El proceso completo de este estudio se encuentra documentado en el repositorio del proyecto. (Acosta Morales and Ramírez Cárdenas, 2026).

BIBLIOGRAFÍA

Acosta Morales, J. E. and Ramírez Cárdenas, I. (2026). Proyecto de predicción de abandono de clientes (churn). Repositorio de GitHub. Disponible en: https://github.com/juanesaacosta26/churn-iran.

Ahn, J.-H., Han, S.-P., and Lee, Y.-S. (2006). Customer churn analysis: Churn determinants and mediation effects of partial defection in the Korean mobile telecommunications service industry. *Telecommunications Policy*, 30(10–11):552–568.

Arai, K., Fujikawa, I., Nakagawa, Y., Momozaki, R., and Ogawa, S. (2023). Churn customer estimation method based on LightGBM for improving sales. *International Journal of Advanced Computer Science and Applications (IJACSA)*, 14(2):119–125.

Blei, D. M., Kucukelbir, A., and McAuliffe, J. D. (2017). Variational inference: A review for statisticians. *Journal of the American Statistical Association*, 112(518):859–877.

Capacity Media (s.f.). Operators spend 90% of subscriber acquisition budget on countering

churn. Informe de Strategy Analytics para Juvo. https://capacitymedia.com/articles/3823134/operators-spend-90-of-subscriber-acquisition-budget-on-countering-churn.

Customer churn in mobile markets (2016). Customer churn in mobile markets: A comparison of techniques. arXiv:1607.07792. https://arxiv.org/pdf/1607.07792.

Gelman, A., Jakulin, A., Pittau, M. G., and Su, Y.-S. (2008). A weakly informative default prior distribution for logistic and other regression models. *The Annals of Applied Statistics*, 2(4):1360–1383.

Gelman, A., Roberts, G. O., and Gilks, W. R. (1996). Efficient Metropolis jumping rules. In *Bayesian Statistics 5*, pages 599–607. Oxford University Press.

Goodrich, B., Gabry, J., Ali, I., and Brilleman, S. (2024). rstanarm: Bayesian applied regression modeling via Stan. Paquete de R. https://mc-stan.org/rstanarm/.

Hoffman, M. D. and Gelman, A. (2014). The No-U-Turn sampler: Adaptively setting path lengths in Hamiltonian Monte Carlo. *Journal of Machine Learning Research*, 15:1593–1623.

Ibrahim, J. G. and Chen, M.-H. (2000). Power prior distributions for regression models. *Statistical Science*, 15(1):46–60.

Iranian Churn (2020). Iranian churn [dataset]. UCI Machine Learning Repository. https://archive.ics.uci.edu/dataset/563/iranian+churn+dataset.

Kazami, M. and HejaziNia, R. (2017). Study affective variables in mobile customers churn. *Journal of Development and Evolution Management*, 8:115–121.

Keramati, A., Jafari-Marandi, R., Aliannejadi, M., Ahmadian, I., Mozaffari, M., and Abbasi, U. (2014). Improved churn prediction in telecommunication industry using data mining techniques. *Applied Soft Computing*, 24:994–1012.

Meyer, D. (2014). Ovum: Churn remains hurdle for mobile operators worldwide. RCR Wireless News, 6 de noviembre. https://rcrwireless.com/20141106/big-data-analytics/ovum-churn-remains-hurdle-for-mobile-operators-worldwide-tag2.

Neal, R. M. (2011). MCMC using Hamiltonian dynamics. In Brooks, S., Gelman, A., Jones, G., and Meng, X.-L., editors, *Handbook of Markov Chain Monte Carlo*, pages 113–162. Chapman & Hall/CRC.

Polson, N. G., Scott, J. G., and Windle, J. (2013). Bayesian inference for logistic models using Pólya-Gamma latent variables. *Journal of the American Statistical Association*, 108(504):1339–1349.

Vatankhah, S., Samizadeh, R., and Namdar Zangeneh, S. (2016). A model for customer churn prediction in the Iranian telecommunication companies. *Journal of Management and Development Process*, 29(2):99–116.

Vehtari, A., Gelman, A., Simpson, D., Carpenter, B., and Bürkner, P.-C. (2021). Rank-normalization, folding, and localization: An improved $\hat{R}$ for assessing convergence of MCMC. *Bayesian Analysis*, 16(2):667–718.

Watanabe, S. (2010). Asymptotic equivalence of Bayes cross validation and widely applicable information criterion in singular learning theory. *Journal of Machine Learning Research*, 11:3571–3594.